Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа №2

по дисциплине «Методы машинного обучения»

на тему«Обработка пропусков в данных»

Выполнил:

студент группы: ИУ5-23М

Аимань Мухэяти

Москва — 2021 г.

1.Цель лабораторной работы: изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей

2.Задание

1.Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)

2.Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:

- устранение пропусков в данных;
- кодирование категориальных признаков;
- нормализацию числовых признаков.

3. Ход выполнения работы

Подключим все необходимые библиотеки

```
In [1]: import numpy as np
        import pandas as pd
        import seaborn as sns
        import sklearn.impute
        import sklearn.preprocessing
        # Enable inline plots
        %matplotlib inline
        # Set plot style
        sns.set(style="ticks")
        # Set plots formats to save high resolution PNG
        from IPython.display import set_matplotlib_formats
        set_matplotlib_formats("retina")
```

Зададим ширину текстового представления данных, чтобы в дальнейшем текст в отчёте влезал на А4 :

```
In [2]: pd.set_option("display.width", 70)
```

Для выполнения данной лабораторной работы возьмём набор данных по приложениям в waetherAUS (Погода в Австралии)

```
In [15]: data = pd.read_csv("weatherAUS.csv")
```

Посмотрим на эти наборы данных:

```
data.head(5)
```

	Date	Location	MinTemp	MaxTemp	Rainfall	Evaporation	Sunshine	WindGustDir	WindGustSpeed	WindDir9am	...	Humidity9am	Humidi
0	2008-12-01	Albury	13.4	22.9	0.6	NaN	NaN	W	44.0	W	...	71.0	
1	2008-12-02	Albury	7.4	25.1	0.0	NaN	NaN	WNW	44.0	NNW	...	44.0	
2	2008-12-03	Albury	12.9	25.7	0.0	NaN	NaN	WSW	46.0	W	...	38.0	
3	2008-12-04	Albury	9.2	28.0	0.0	NaN	NaN	NE	24.0	SE	...	45.0	
4	2008-12-05	Albury	17.5	32.3	1.0	NaN	NaN	W	41.0	ENE	...	82.0	

5 rows × 23 columns

```
In [17]: data.dtypes
Out[17]: Date             object
         Location         object
         MinTemp         float64
         MaxTemp         float64
         Rainfall        float64
         Evaporation     float64
         Sunshine        float64
         WindGustDir      object
         WindGustSpeed   float64
         WindDir9am       object
         WindDir3pm       object
         WindSpeed9am    float64
         WindSpeed3pm    float64
         Humidity9am     float64
         Humidity3pm     float64
         Pressure9am     float64
         Pressure3pm     float64
         Cloud9am        float64
         Cloud3pm        float64
         Temp9am         float64
         Temp3pm         float64
         RainToday        object
         RainTomorrow     object
         dtype: object
```

```
In [18]: data.shape
Out[18]: (145460, 23)
```

3.1. Обработка пропусков в данных

Найдем все пропуски в данных:

```
In [19]: data.isnull().sum()
```

```
Out[19]: Date                0
         Location            0
         MinTemp          1485
         MaxTemp          1261
         Rainfall         3261
         Evaporation     62790
         Sunshine        69835
         WindGustDir     10326
         WindGustSpeed   10263
         WindDir9am      10566
         WindDir3pm       4228
         WindSpeed9am     1767
         WindSpeed3pm     3062
         Humidity9am      2654
         Humidity3pm      4507
         Pressure9am     15065
         Pressure3pm     15028
         Cloud9am        55888
         Cloud3pm        59358
         Temp9am          1767
         Temp3pm          3609
         RainToday        3261
         RainTomorrow     3267
         dtype: int64
```

Очевидно, что мы будем работать с колонкой MinTemp. Самый простой вариант — заполнить пропуски нулями:

```
In [20]: sns.distplot(data["MinTemp"].fillna(0));
```

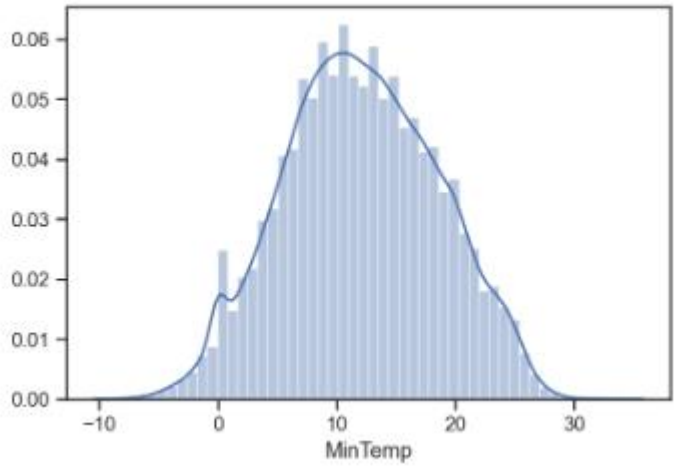

Видно, что в данной ситуации это приводит к выбросам. Логичнее было бы приложениям без рейтинга присваивать средний рейтинг:

```
mean_imp = sklearn.impute.SimpleImputer(strategy="mean")
mean_mintemp = mean_imp.fit_transform(data[["MinTemp"]])
sns.distplot(mean_mintemp);
```

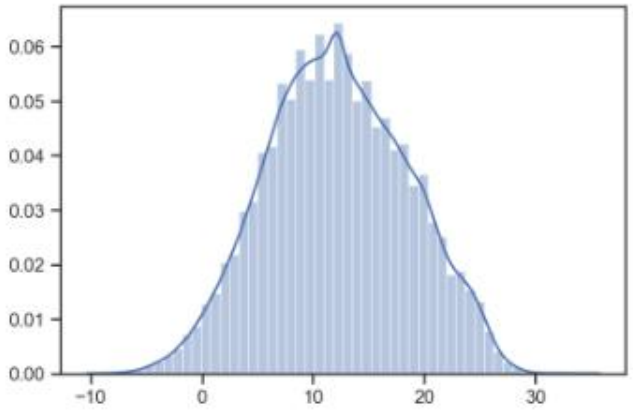

Попробуем также медианный рейтинг и самый частый рейтинг:

```
med_imp = sklearn.impute.SimpleImputer(strategy="median")
med_mintemp = med_imp.fit_transform(data[["MinTemp"]])
sns.distplot(med_mintemp);
```

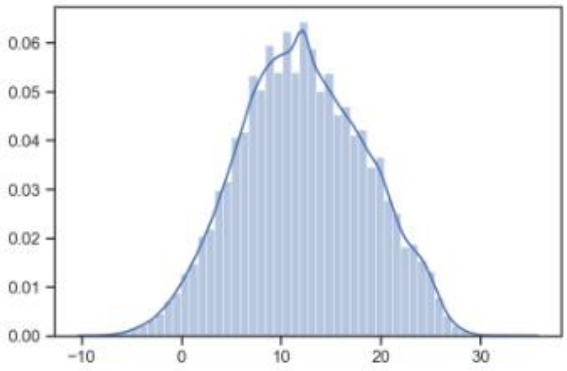


```
freq_imp = sklearn.impute.SimpleImputer(strategy="most_frequent")
freq_mintemp = freq_imp.fit_transform(data[["MinTemp"]])
sns.distplot(freq_mintemp);
```

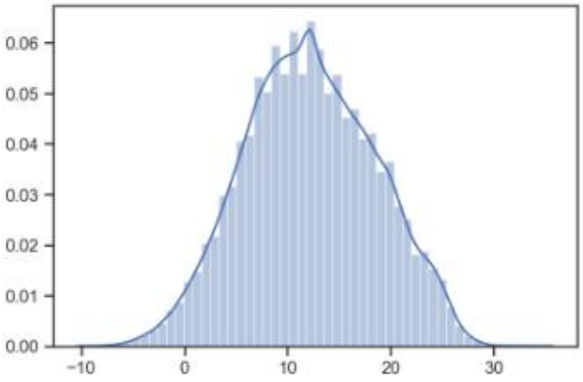

Как видно, эти три значения очень близки к нормальному распределению , поэтому выбираем любое из них на линии, здесь выбираем среднее

```
data["MinTemp"] = mean_mintemp
```

3.2. Кодирование категориальных признаков

Рассмотрим колонку WindGustDir:

```
wgd= data["WindGustDir"].dropna().astype(str)
wgd.value_counts()
```

```
W      9915
SE     9418
N      9313
SSE    9216
E      9181
S      9168
WSW    9069
SW     8967
SSW    8736
WNW    8252
NW     8122
ENE    8104
ESE    7372
NE     7133
NNW    6620
NNE    6548
Name: WindGustDir, dtype: int64
```

Выполним кодирование категорий целочисленными значениями:

In [38]:
```
le = sklearn.preprocessing.LabelEncoder()
wgd_le = le.fit_transform(wgd)
print(np.unique(wgd_le))
le.inverse_transform(np.unique(wgd_le))
```

```
[ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15]
```

Out[38]:
```
array(['E', 'ENE', 'ESE', 'N', 'NE', 'NNE', 'NNW', 'NW', 'S', 'SE', 'SSE',
       'SSW', 'SW', 'W', 'WNW', 'WSW'], dtype=object)
```

Выполним кодирование категорий наборами бинарных значений:

```
wgd_oh = pd.get_dummies(wgd)
wgd_oh.head()
```

	E	ENE	ESE	N	NE	NNE	NNW	NW	S	SE	SSE	SSW	SW	W	WNW	WSW
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
2	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1
3	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0

```
wgd_oh[wgd_oh["W"] == 1].head()
```

	E	ENE	ESE	N	NE	NNE	NNW	NW	S	SE	SSE	SSW	SW	W	WNW	WSW
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
6	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
7	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
9	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0

3.3. Масштабирование данных

Для начала попробуем обычное MinMax-масштабирование:

```
mm = sklearn.preprocessing.MinMaxScaler()
sns.distplot(mm.fit_transform(data[["MinTemp"]]));
```

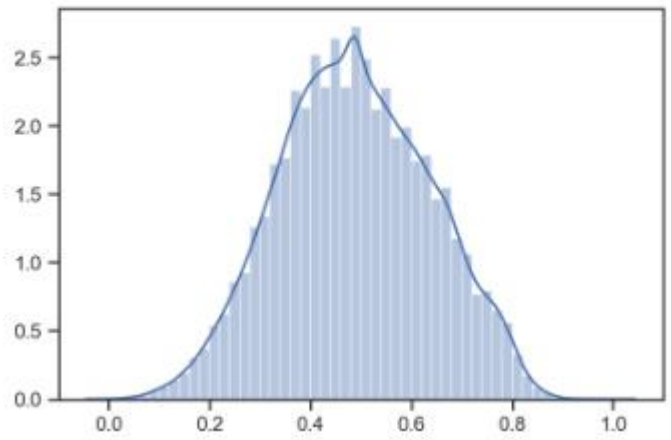

Результат вполне ожидаемый и вполне приемлемый. Но попробуем и другие вари-анты, например, масштабирование на основе Z-оценки:

```
ss = sklearn.preprocessing.StandardScaler()
sns.distplot(ss.fit_transform(data[["MinTemp"]]));
```

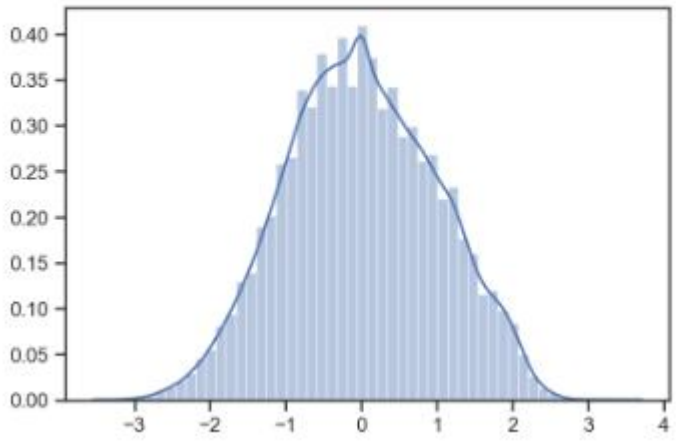

Также результат ожидаемый, но его применимость зависит от дальнейшего использования.

Список литературы

[1] Гапанюк Ю. Е. Лабораторная работа «Обработка признаков» [Электронный ресурс] https://github.com/ugapanyuk/ml_course_2021/wiki/LAB_MMO__FEATURES